DeepShift IA Academy

Small Language Models Benchmarking

Présenté par Andolsi Tayssir et Frigui Youssef

Plan

1. Introduction
2. Agent OCR/exctraction
3. Agents de vérification de conformité interne et de controle inter-documents

Introduction

Agent OCR / Extraction

- **But** : Évaluer la précision et l'efficacité de 7 modèles d'extraction de texte sur des documents bancaires.
- **Cas d'usage** : Automatisation des flux KYC (Know Your Customer) et KYB (Know Your Business).
- **Méthodologie** :
  - Pipeline reproductible via Jupyter Notebook.
  - Automatisation complète : chargement → inférence → calcul des métriques → agrégation.

Dataset

- Nature des documents : Formulaires administratifs en français.
- Volume : 150 images
- Prétraitement (Normalisation) :
  - Normalisation Unicode NFKC.
  - Mise en minuscule et suppression des espaces superflus.
  - Gestion des apostrophes et suppression des caractères non-alphanumériques (conservation des accents français).

Exemple d’image

- [images à ajouter]

Modèles Évalués

- OCR Traditionnels :
  - Tesseract & EasyOCR.
- Modèles de Vision-Langage :
  - GLM-OCR
  - Ministral3-3b
  - Gemma-3
  - Qwen3-vl-2b
  - DeepSeek-OCR

Métriques de Performance

- WER (Word Error Rate) : Taux d'erreur par mot .
- CER (Character Error Rate) : Taux d'erreur par caractère .
- Score F1 : Équilibre entre Précision (exactitude) et Rappel (exhaustivité)
- Latence : Temps de réponse par document
- Taux d'échec : Nombre de prédictions vides.
    -

Exemple d’output

- [images à ajouter]

Resultats

Model	WER↓	CER↓	Precision↑	Recall↑	F1↑	Latency	Empty
glm-ocr	**0.23**	**0.18**	**0.94**	**0.83**	**0.88**	16.99s	0
easyocr	0.25	0.14	**0.94**	0.82	0.87	38.11s	0
ministral3-3b	0.27	0.22	0.92	0.78	0.84	18.21s	0
tesseract	0.31	0.23	0.88	0.82	0.85	**3.74s**	0
qwen3-vl-2b	0.85	0.77	0.53	0.44	0.48	27.12s	0
gemma-3	0.90	0.85	0.24	0.11	0.15	33.04s	0
deepseek-ocr	**0.95**	**0.92**	**0.09**	**0.09**	**0.09**	21.49s	0

Agent de conformité et Agent de contrôle(Cross-check)

- **But Agent de confirmité** : Vérifie la logique interne des informations de chaque formulaire
- **But Agent de controle :** Vérifie la cohérence inter-documents (KYC, Fiscal, Identité).

Donnés

Agent confirmité

conform

```
{
 "type_formulaire": "
     FATCA_INDIVIDUAL",
 "statut_us_person": true,
 "numero_tin": "459-34-2557",
 "est_signe": true,
 "indices_americanite": {
  "naissance_us": true,
  "virement_vers_us": true
 }
}
```

```
{
 "profession": "Entrepreneur",
 "tranche_revenu_annuel": "80k-10
     0k TND",
 "origine_fonds": "Epargne
     personnelle",
 "ppe_statut": false,
 "secteur_activite": "Finance"
}
```

non conform

"FATCA_TIN_REQUIRED"

```
{
 "type_formulaire": "
     FATCA_INDIVIDUAL",
 "statut_us_person": true,
 "numero_tin": "",
 "est_signe": true,
 "indices_americanite": {
  "naissance_us": true,
  "virement_vers_us": false
 }
}
```

"KYC_PROFILE_INCOME_INCOHERENT

```
{
 "profession": "ouvrier",
 "tranche_revenu_annuel": "> 100k
     TND",
 "origine_fonds": "Inconnue",
 "ppe_statut": false,
 "secteur_activite": "Inconnue"
}
```

Agent contrôle

conform

```
{
 "identite_doc": {
  "type_document": "CNI",
  "lieu_naissance": "Los Angeles"
      ,
  "nationalite": "Americaine",
  "date_naissance": "1985-07-15",
  "nom": "Smith",
  "adresse": "Etats-Unis"
 },
 "fiscalite_form": {
  "type_formulaire": "
      FATCA_INDIVIDUAL",
  "statut_us_person": true,
  "numero_tin": "459-34-2557",
  "est_signe": true,
  "indices_americanite": {
   "naissance_us": true,
   "virement_vers_us": true
  }
 },
 "profil_kyc": {
  "profession": "Entrepreneur",
  "tranche_revenu_annuel": "80k-1
      00k TND",
  "origine_fonds": "Epargne
      personnelle",
  "ppe_statut": false,
  "secteur_activite": "Finance"
 }
}
```

non conform

Indice d'americanite (Lieu de naissance) contredit avec FATCA

```
{
 "identite_doc": {
  "type_document": "Passeport",
  "lieu_naissance": "New York",
  "nationalite": "Americaine",
  "date_naissance": "1992-01-02",
  "nom": "Rossi"
 },
 "fiscalite_form": {
  "type_formulaire": "
      FATCA_INDIVIDUAL",
  "statut_us_person": false,
  "numero_tin": "",
  "est_signe": true,
  "indices_americanite": {
   "naissance_us": true,
   "virement_vers_us": false
  }
 },
 "profil_kyc": {
  "profession": "Architecte",
  "tranche_revenu_annuel": "60k-8
      0k TND",
  "origine_fonds": "Dividendes",
  "ppe_statut": false,
  "secteur_activite": "
      Construction"
 }
}
```

Les modèles sélectionnés

Model	taille	Context	Année
qwen2.5:3b	3b	32k	Sep 2024
qwen:1.8b	1.8b	8k	Dec 2023
qwen3:1.7b	1.7b	32k	Avril 2025
qwen3:0.6b	0.6b	32k	Avril 2025
phi-mini-instruct:4b	4b	128k	février 2025
phi-latest:2.7b	2.7b	2k	Juin 2024
daulphin-phi:2.5b	2.5b	2k	Décembre 2023
smollm2:1.7b	1.7b	64k	Novembre 2024
deepseek-r1:1.5b	1.5b	128k	Juillet 2024
gemma3:1b	1b	128k	Décembre 2025

- *Des modèles de trés petite taille*
- *Capacité de raisonnement*
- *Popularité*

Exemples d'output

Agent de Conformité

```
[45/50] kyc_08.json: --- Utilisation de Ollama Local: qwen3:1.7b ---
IA:NON CONFIRMED (CORRECT) | Alertes: [KYC_PROFILE_INCOME_INCOHERENT] | 7.07s
[46/50] kyc_09.json: --- Utilisation de Ollama Local: qwen3:1.7b ---
IA:NON CONFIRMED (CORRECT) | Alertes: [KYC_PPE_DOC_REQUIRED] | 7.15s
[47/50] kyc_10.json: --- Utilisation de Ollama Local: qwen3:1.7b ---
IA:NON CONFIRMED (CORRECT) | Alertes: [KYC_PPE_DOC_REQUIRED] | 8.42s
[48/50] kyc_11.json: --- Utilisation de Ollama Local: qwen3:1.7b ---
IA:NON CONFIRMED (CORRECT) | Alertes: [KYC_PROFILE_INCOME_INCOHERENT,KYC_PPE_DOC_REQUIRED] | 7.16s
[49/50] kyc_12.json: --- Utilisation de Ollama Local: qwen3:1.7b ---
IA:NON CONFIRMED (CORRECT) | Alertes: [KYC_PROFILE_INCOME_INCOHERENT] | 10.95s
[50/50] kyc_13.json: --- Utilisation de Ollama Local: qwen3:1.7b ---
IA:NON CONFIRMED (CORRECT) | Alertes: [KYC_PPE_DOC_REQUIRED] | 9.65s
```

Agent du contôle

```
26/29: file06.json:
--- Utilisation de Ollama Local: qwen3:1.7b ---
-> INVESTIGATION_REQUISE (CORRECT) | 17.75s
-->Raison: Résidence fiscale déclarée (Maroc) différente de l'adresse de correspondance (France)

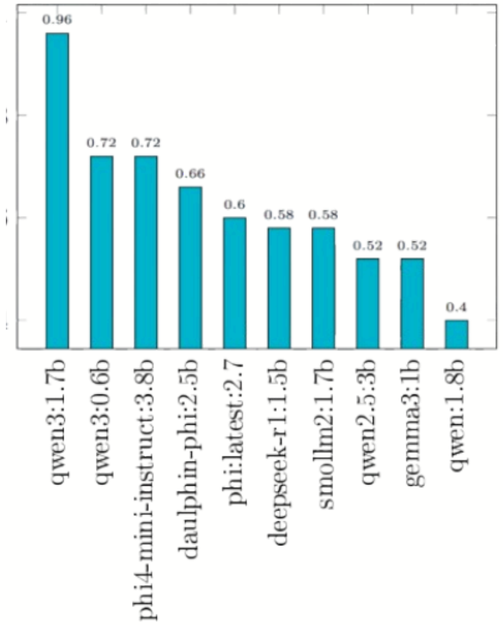
27/29: file07.json:
--- Utilisation de Ollama Local: qwen3:1.7b ---
-> REJET (CORRECT) | 14.57s
-->Raison: Profil professionnel incohérent avec les revenus déclarés.

28/29: file08.json:
--- Utilisation de Ollama Local: qwen3:1.7b ---
-> REJET (CORRECT) | 15.49s
-->Raison: Profil professionnel incohérent avec les revenus déclarés.

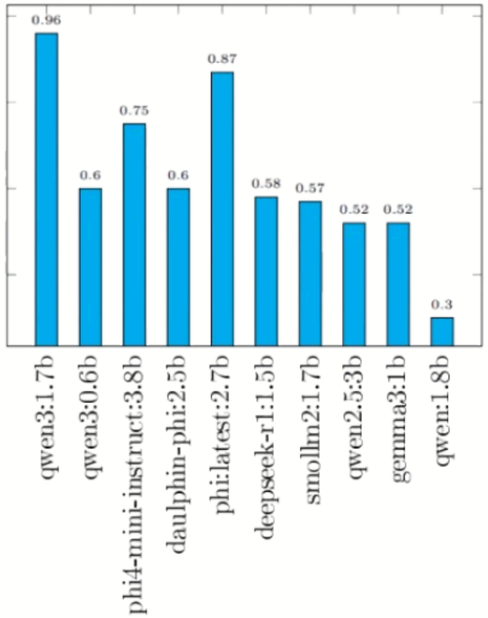
29/29: file09.json:
--- Utilisation de Ollama Local: qwen3:1.7b ---
-> REJET (CORRECT) | 29.95s
-->Raison: Profil professionnel incohérent avec les revenus déclarés.
```

Résultats

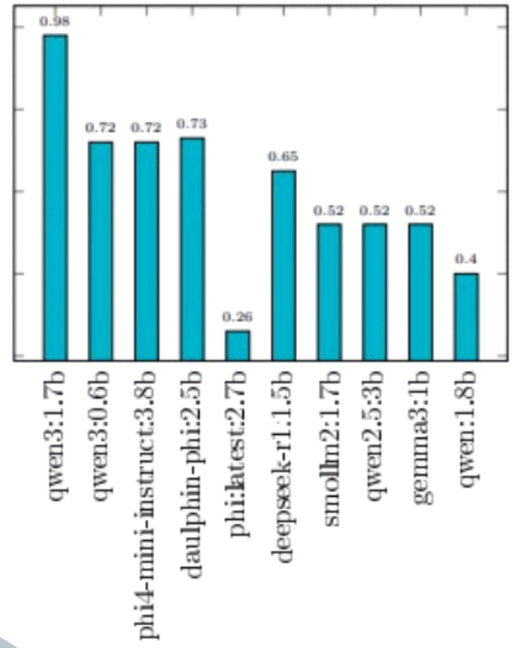
Accuracy



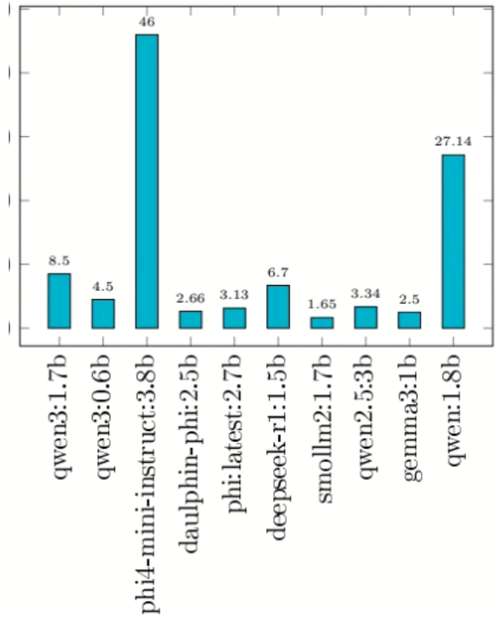
Précision



Recall



Temps de réponse moyen



Conclusion

Thank You

Presented by Hannah Morales